Centro Universitário de Excelência
Sistemas de Informação

Introdução ao Pré-processamento de Dados

Autor: Antônio Gabriel Gomes Falcão do Nascimento
Giovanna Oliveira Araujo
Gustavo Costa Pereira
João Magalhães Mira Neto

Feira de Santana, 2026

Agenda

O objetivo desta apresentação é evidenciar de que forma transformamos dados brutos e inconsistentes em um formato limpo e compreensível para a aplicação do Dendê Softhouse.

1. Contextualização
Continuação do desafio do programa de trainee do Dendê Softhouse

2. Tipos de Operação
Classificação das etapas de Limpeza, Transformação e Codificação

3. Processamento de Dados Ausentes ou Nulos:
Estratégias de remoção e imputação estatística

4. Transformadores de Escala:
Uso de Normalização e Padronização

5. Codificadores de Valores Categóricos:
Conversão de dados qualitativos em representações numéricas através de *Label e One-Hot Encoding*

6. Aplicação da Operação no Dataset Spotify:
Demonstração prática dos algoritmos na preparação da base Spotify

1. Dendê-Statistics

Modelo de Recomendação para Dendê-Eventos

Etapas		
1	Análise Exploratória	Modelo de aplicação para análise
2	**Pré-Processamento**	**Limpeza de dados**
3	Algoritmos de Regra de Associação	Descoberta de padrões de consumo e afinidade
4	Modelo de Predição	Descoberta de padrões de consumo e afinidade

2. Tipos de Operação

Categoria	Classe	Principais Técnicas e Fórmulas
Limpeza	MissingValueProcessor	**Imputação:** Preenchimento por média/mediana **Remoção:** dropna de registros incompletos.
Escalonamento	Scaler	**Min-Max:** Dados entre 0 e 1 $\frac{\text{valor atual - menor valor}}{\text{denominador}}$ **Standard:** Define a média em 0 e o desvio padrão em 1 $\frac{\text{valor atual - média}}{\text{desvio padrão}}$
Codificação	Encoder	**Label:** Identificadores inteiros para dados ordinais. **One-Hot:** Colunas binárias para dados nominais.

3. Processamento de Dados Ausentes ou Nulos

`isna()` – Filtragem de registros com valores nulos

Entrada	[19, None, 54, None, 21] [19, 24, 54, 34, 21]
Saída	[19, None, 54, None, 21]

`fillna()` – Preenchimento de valores ausentes

Entrada	[19, None, 54, None, 21]

Valor = 0 →

Saída	[19, 0, 54, 0, 21]

`notna()` – Filtragem lógica de dados válidos

Entrada	[19, None, 54, None, 21]
Saída	[19, 54, 21]

`dropna()` – Remoção de registros incompletos

Entrada	[19, None, 54, None, 21]
Saída	[19, 54, 21]

4. Transformadores de Escala

Os **Transformadores de Escala** (ou *Scalers*) são ferramentas de pré-processamento essenciais que ajustam a magnitude numérica das suas variáveis.

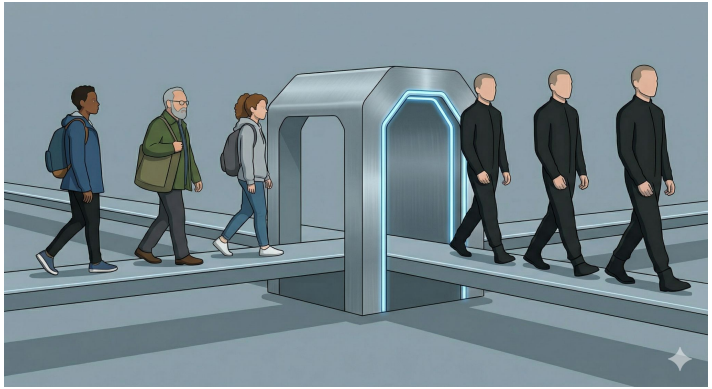

NORMALIZAÇÃO

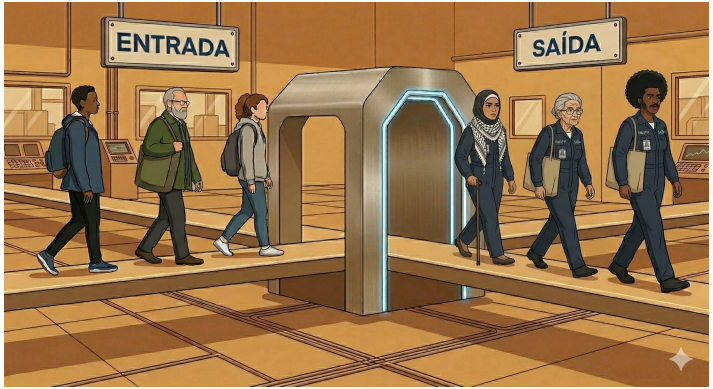

PADRONIZAÇÃO

*IMAGENS GERADAS POR IA

4.1 Transformadores de Escala

NORMALIZAÇÃO

A normalização comprime resultados todo tipo de valor para um intervalo fixo(0-1), usando a seguinte fórmula:

$$\text{normalização} = \frac{\text{valor atual - menor valor}}{\text{denominador}}$$

PADRONIZAÇÃO

A padronização, transforma os dados com base em estatísticas populacionais transformando a média em 0 e o desvio padrão em 1, com a seguinte fórmula:

$$\text{padronização} = \frac{\text{valor atual - média}}{\text{desvio padrão}}$$

4.2 Transformadores de Escala

NORMALIZAÇÃO

SALÁRIO ORIGINAL	CÁLCULO	RESULTADO PADRÃO
1000	$\frac{1000-1000}{9000}$	0.0
5000	$\frac{5000-1000}{9000}$	0.44
10000	$\frac{10000-1000}{9000}$	1.0

PADRONIZAÇÃO

IDADE ORIGINAL	POSIÇÃO RELATIVA	RESULTADO PADRONIZADO
25 ANOS	ABAIXO DA MÉDIA	-1.0
38 ANOS	MÉDIA	0.0
60 ANOS	ACIMA DA MÉDIA	+1.6

5. Codificadores de Valores Categóricos

Encoder

Encoder é uma técnica de pré-processamento utilizada para converter **dados nominais** (texto, categorias, rótulos) em dados numéricos.

Label Encoding

Para dados ordinais.

priority = [”médio”,“baixo”,”alto”]

↓

priority = set([“1”,”2”,”3”])

1* ***Com viés***

One-Hot Encoding

Para dados categóricos.

	Show	**Palestra**	**Workshop**
Show	1	0	0
Palestra	0	1	0
Workshop	0	0	1

1* ***Sem viés***

6. Aplicação da Operação no Dataset Spotify

1. **Processamento de Dados Ausentes (MissingValueProcessor)**

2. **Transformadores de Escala (Scaler)**

3. **Codificadores de Valores Categóricos (Encoder)**

```
[1/3] Tratando nulos e integridade...
[2/3] Escalonando dados numéricos...
[3/3] Codificando categorias...

--- AMOSTRA DO DATASET PROCESSADO ---

2*====================================================================
| ARTISTA                  | MÚSICA                    | POPULARIDADE
--------------------------------------------------------------------
Diplo                      | Trippy Mane (ft. Project  |      -2.1985
Yelawolf                   | OMG!                      |      -2.1985
Riff Raff                  | Hard 2 Find               |      -2.0305
Diplo                      | Still Get Like That (ft.  |      -0.9388
Rumelis                    | ride me like a harley     |      -2.1985
Minzie                     | BLEED                     |      -2.1145
AZERDK                     | Te Procuro na Cidade      |      -1.3587
Rumelis                    | come closer               |      -1.0647
Toni dos Anjos             | Cupido Vagabundo          |      -1.5266
PsychoYP                   | LET'S GO!                 |      -0.8128
What Matters The Most      | Stray                     |      -0.9388
A20                        | PAPARAZZI ARRIVE - Englis |      -0.1829
Daniel Caesar              | Root of all Evil          |       0.5309
Ovi Jozi                   | Let's Go!!                |      -2.1985
A20                        | MELODY - CHENYU & SHIJIE  |      -1.0647
Leon Thomas                | My Muse                   |       0.6149
Joe Hermes                 | A Real Good Bad One       |      -0.8968
A20                        | BOSS - English Ver.       |      -0.8128
```

Referências

- [1]Cristian S. M. e Deborah R. C. (2013) “Pós-processamento em KDD: uma abordagem baseada em regras de associação. Revista de Engenharia e Tecnologia”, São Paulo, v. 5, n. 1, p. 170-499, abr. 2013.
- [2]**SPOTIFY**. *Spotify Songs for ML & Analysis*. [S. l.]: Kaggle/Spotify, 2026. Disponível em: https://www.kaggle.com. Acesso em: 15 mar. 2026.